


## Identificação de praga de mosca-da-fruta (*Ceratitis capitata*) usando YOLOv8



Rafael Rodrigues 27888  
Filipe Felisardo 28088

Ano letivo 2023/2024

# Introdução

Este trabalho tem como objetivo facilitar a monitorização da mosca-da-fruta (*Ceratitis capitata*), uma praga agrícola que pode provocar grandes estragos e prejuízos a agricultores que não realizem uma monitorização e não façam um controlo adequado. A mosca-da-fruta, afeta diversas culturas, e a deteção e identificação eficazes desta praga são cruciais para a implementação de medidas de controlo, visando minimizar os prejuízos e as perdas económicas.

O projeto dá uma certa continuidade ao trabalho desenvolvido na cadeira de Introdução ao Python, onde agora utilizamos o algoritmo YOLOv8, um modelo de deteção de objetos, para identificar e contar com precisão a mosca da fruta em armadilhas através de imagens e vídeos. Este projeto visa fornecer uma ferramenta para agricultores e técnicos agrícolas para ajudar a fazer a monitorização das populações de moscas-da-fruta.

## Data

**Descrição dos dados:** O conjunto de dados inclui mais de 4.000 imagens da mosca-da-fruta, que já vinham anotadas para incluir caixas delimitadoras à volta das moscas-da-fruta, caso assim não fosse teríamos de usar uma aplicação para manualmente identificarmos a mosca em cada imagem.

**Limpeza e transformação de dados:** Não foi necessária nenhuma limpeza ou transformação dos dados sendo apenas preciso organizar os ficheiros e garantir que estivessem anotados corretamente pois as imagens foram usadas como estavam para treinar o modelo, uma vez que estas já vinham preparadas (com algum pré-processamento feito como por exemplo o tamanho de 640x640) para implementar o modelo yolov8.

**Seleção e engenharia de características:**

Uma vez que o objetivo era detetar e contar moscas da fruta, não foi necessária qualquer engenharia de características adicional para além das caixas delimitadoras anotadas.

# Data Organization

## Conjuntos de treino, validação e teste:

Conjunto de treino: Contém 70% das imagens que foram utilizadas para treinar o modelo, garantindo uma grande variedade de contextos da mosca da fruta em diversas situações.

Conjunto de validação: Contém 15% das imagens que foram utilizadas para ajustar os hiper parâmetros e evitar o overfitting, monitorizando o desempenho do modelo com dados não conhecidos durante o treino.

Conjunto de teste: Contém 15% das imagens e é mantido até a avaliação final para obter uma avaliação neutra do desempenho do modelo.

## Métodos

O modelo de *machine learning* utilizado foi o YOLOv8, este modelo tem um bom desempenho em detecção de objetos com um equilíbrio entre a velocidade e a precisão para detetar os objetos. Além disso tem boas capacidades para a detecção e processamento em tempo real sendo possível incorporar numa câmara para recolher dados.

Este modelo foi ajustado utilizando os seguintes parâmetros:

- Epochs: 30
- Tamanho do lote: Tamanho apropriado com base na memória da CPU
- Taxa de aprendizagem: Ajustado usando o desempenho do conjunto de validação
- Tamanho da imagem: 640x640 pixéis


## Resultados

O desempenho do modelo foi avaliado usando métricas de precisão, e pontuação F1. Os resultados são apresentados em baixo em formato de gráfico.

A imagem (Figura1) apresenta um gráfico da Curva de Confiança F1, ilustrando a relação entre a confiança do modelo nas suas previsões e o desempenho medido pela pontuação F1.

O pico de desempenho ocorre com uma pontuação máxima de F1 de aproximadamente 0,86, a um nível de confiança de 0,423, indicando que, nesse limite de confiança, o modelo atinge um melhor equilíbrio.

Além desse limiar de confiança de 0,423, a pontuação F1 começa a diminuir, sugerindo que, embora o modelo se torne mais confiante nas suas previsões, pode estar a fazer previsões mais precisas, mas menos corretas.



*Figura 1- F1*

A imagem mostra a análise da Matriz de Confusão Normalizada, onde é possível observar que o algoritmo apresenta uma precisão elevada para a categoria "mosca" (definida para identificar a mosca-da-fruta) com um valor de 0,91. Isto sugere que o modelo é bastante preciso para identificar "mosca". Além disso, a precisão na classificação de "background" é perfeita, com valores de 1.00, indicando que o modelo

não cometeu erros na classificação do "background".




Figura 2 - Matriz de confusão normalizada

A imagem (Figura 3) mostra uma série de gráficos que representam as métricas de formação e validação para o modelo de *machine learning* ao longo de 30 Epochs.

Os gráficos têm resultados reais (linhas azuis) e resultados suavizados (linhas pontilhadas laranja). A suavização ajuda a visualizar a tendência geral, reduzindo o ruído.

As métricas de perda de treino e validação mostram uma clara tendência de queda, sugerindo que o modelo está a aprender com eficácia e não está a sofrer *overfitting*.

As métricas de precisão, recuperação e mAP estão todas a melhorar, o que confirma que a precisão do modelo na deteção e classificação de objetos está a aumentar ao longo do tempo.

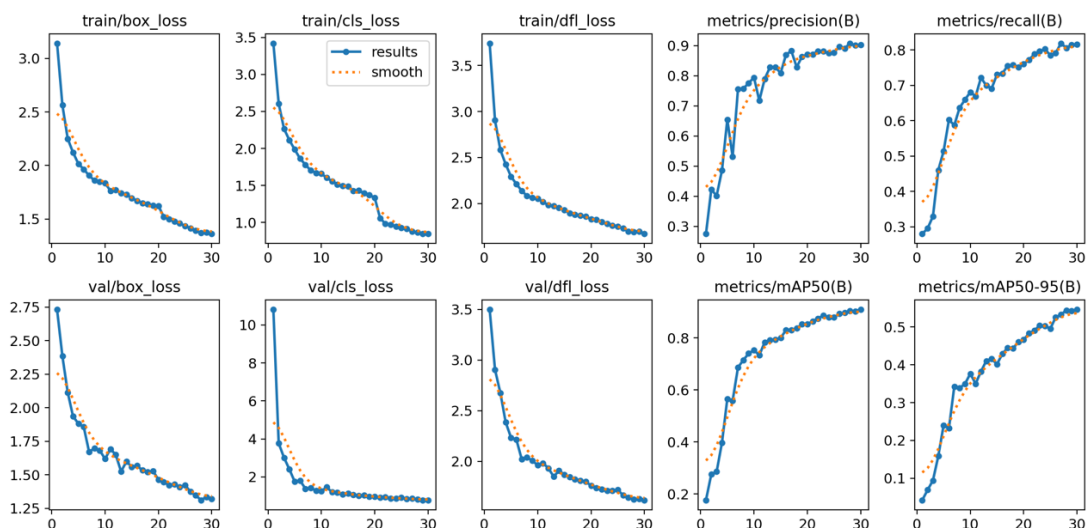
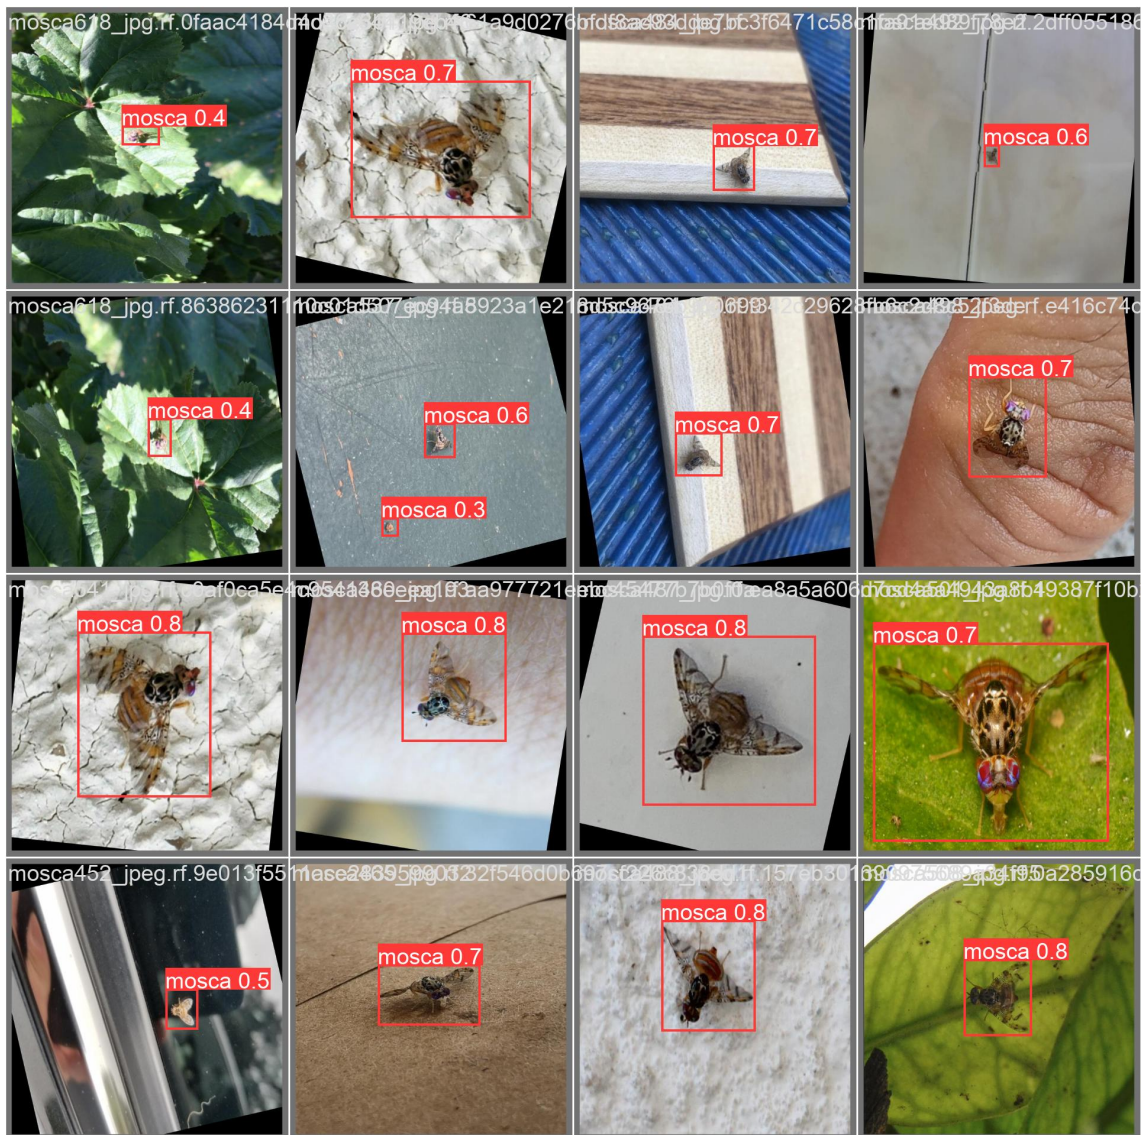


Figura 3 - Gráficos com métricas de formação e validação

## Análise

O modelo YOLOv8 demonstrou uma boa precisão na detecção da mosca-da-azeitona tanto em imagens como em vídeos. A precisão do modelo indica que é eficaz na identificação e contagem de moscas da fruta com um mínimo de falsos positivos e falsos negativos. A capacidade de detecção em tempo real torna o modelo adequado para a monitorização contínua em meios agrícolas.

Na imagem abaixo podemos ver o algoritmo a fazer a identificação da mosca (*ceratitis capitata*) e com o nível de confiança.



## Referências

<https://docs.ultralytics.com/>

<https://mariofilho.com/precisao-recall-e-f1-score-em-machine-learning/>